

LeGO-LOAM：轻量级、地面优化的可变地形激光雷达里程计和测绘

单提晓和 Brendan Englot

抽象的—我们提出了一种轻量级、地面优化的激光雷达里程计和测绘方法 LeGO-LOAM，用于实时六自由度地面车辆姿态估计。LeGO-LOAM 是轻量级的，因为它可以在低功耗嵌入式系统上实现实时姿态估计。LeGO-LOAM 是地面优化的，因为它在分割和优化步骤中利用了地面平面的存在。我们首先应用点云分割来滤除噪声，然后应用特征提取来获得独特的平面和边缘特征。然后，两步 Levenberg-Marquardt 优化方法使用平面和边缘特征来解决连续扫描中六自由度变换的不同分量。我们使用从地面车辆的可变地形环境中收集的数据集，将 LeGO-LOAM 的性能与最先进的方法 LOAM 进行了比较，并表明 LeGO-LOAM 在降低计算成本的情况下实现了相似或更好的精度。我们还将 LeGO-LOAM 集成到 SLAM 框架中，以消除漂移引起的姿势估计误差，并使用 KITTI 数据集进行测试。

我引言

在智能机器人的功能中，地图构建和状态估计是最基本的先决条件之一。人们已经投入了巨大的努力来实现实时 6 自由度同步定位和地图构建 (SLAM)，方法是使用基于视觉和基于激光雷达的方法。虽然基于视觉的方法在回环检测方面具有优势，但它们对照明和视点变化的敏感性可能会使这种功能在用作唯一导航传感器时变得不可靠。另一方面，基于激光雷达的方法即使在夜间也能发挥作用，而且许多 3D 激光雷达的高分辨率允许在大孔径下远距离捕捉环境的精细细节。因此，本文重点介绍如何使用 3D 激光雷达来支持实时状态估计和地图构建。

寻找两次激光雷达扫描之间的变换的典型方法是迭代最近点 (ICP) [1]。通过逐点寻找对应关系，ICP 迭代地对齐两组点，直到满足停止标准。当扫描包含大量点时，ICP 可能会面临过高的计算成本。已经提出了许多 ICP 变体来提高其效率和准确性 [2]。[3] 引入了一种点到平面 ICP 变体，将点与局部平面斑块匹配。广义 ICP [4] 提出了一种匹配两次扫描中的局部平面斑块的方法。此外，几种 ICP 变体已经利用并行计算来提高效率 [5]–[8]。

基于特征的匹配方法正受到越来越多的关注，因为它们通过从环境中提取代表性特征，所需的计算资源较少。这些特征应该适合有效匹配并且具有视点不变性。已经提出了许多检测器，例如点特征直方图 (PFH) [9] 和视点特征直方图 (VFH) [10]，用于使用简单有效的技术从点云中提取此类特征。[11] 介绍了一种使用 Kanade-Tomasi 角点检测器从点云中提取通用特征的方法。[12] 讨论了一种从密集点云中提取线和平面特征的框架。

还提出了许多使用特征进行点云配准的算法。[13] 和 [14] 提出了一种关键点选择算法，该算法在局部聚类中执行点曲率计算。然后使用所选关键点进行匹配和位置识别。通过将点云投影到范围图像上并分析深度值的二阶导数，[15] 从曲率高的点中选择特征进行匹配和位置识别。假设环境由平面组成，[16] 提出了一种基于平面的配准算法。户外环境（例如森林）可能会限制这种方法的应用。[17] 提出了一种专为 Velodyne 激光雷达设计的领线段 (CLS) 方法。CLS 使用来自扫描的两个连续“环”的点随机生成线。因此生成了两个线云并用于配准。然而，这种方法面临着随机生成线所带来的挑战。[18] 提出了一种基于分割的配准算法。SegMatch 首先将分割应用于点云。然后根据每个片段的特征值和形状直方图计算其特征向量。使用随机森林匹配来自两次扫描的片段。虽然此方法可用于在线姿势估计，但它只能以约 1Hz 的频率提供定位更新。

[19] 和 [20] 提出了一种低漂移实时激光雷达测距与测绘 (LOAM) 方法。LOAM 执行点特征与边缘/平面扫描匹配，以找到扫描之间的对应关系。通过计算局部区域中点的粗糙度来提取特征。粗糙度值高的点被选为边缘特征。类似地，粗糙度值低的点被指定为平面特征。通过将估计问题新颖地划分为两个单独的算法，实现了实时性能。一种算法以高频率运行并以低精度估计传感器速度。另一种算法以低频率运行，但返回高

T. Shan 和 B. Englot 就职于新泽西州霍博肯市哈德逊河畔卡斯尔角史蒂文斯理工学院机械工程系
07030 美国，{TShan3, 工学学士}@stevens.edu.

精度运动估计。将两个估计值融合在一起，以高频率和高精度产生单个运动估计。LOAM 的最终精度是 KITTI 里程计基准站点上仅使用激光雷达的估计方法所达到的最佳精度 [21]。

在本研究中，我们追求对配备 3D 激光雷达的地面车辆进行可靠、实时的六自由度姿态估计，以便能够在小型嵌入式系统上高效实施。这样的任务并非易事，原因有几个。许多无人地面车辆 (UGV) 由于尺寸有限，没有悬架或强大的计算单元。小型 UGV 在多变的地面上行驶时经常会遇到非平稳运动，因此获取的数据通常会失真。由于运动较大且重叠有限，因此在两次连续扫描之间也很难找到可靠的特征对应关系。除此之外，从 3D 激光雷达接收到的大量点对使用有限的机载计算资源进行实时处理提出了挑战。

当我们为此类任务实施 LOAM 时，如果 UGV 在稳定的特征下以平稳运动运行，并得到足够的计算资源支持，我们可以获得低漂移运动估计。然而，当资源有限时，LOAM 的性能会下降。由于需要计算密集 3D 点云中每个点的粗糙度，轻量级嵌入式系统上的特征提取更新频率无法始终跟上传感器更新频率。在嘈杂环境中运行 UGV 也对 LOAM 提出了挑战。由于激光雷达的安装位置通常靠近小型 UGV 上的地面，因此来自地面的传感器噪声可能持续存在。例如，来自草地的距离返回可能导致高粗糙度值。因此，可能会从这些点中提取不可靠的边缘特征。类似地，也可以从树叶返回的点中提取边缘或平面特征。这些特征通常不可靠，无法进行扫描匹配，因为在两次连续的扫描中可能看不到相同的草叶或叶子。使用这些特征可能会导致配准不准确和漂移较大。

因此，我们提出了一种轻量级、地面优化的 LOAM (LeGO-LOAM)，用于在地形多变的复杂环境中估计 UGV 的姿态。LeGO-LOAM 是轻量级的，因为可以在嵌入式系统上实现实时姿态估计和映射。进行点云分割以丢弃地面分离后可能代表不可靠特征的点。LeGO-LOAM 也是地面优化的，因为我们引入了两步优化来估计姿态。从地面提取的平面特征用于获得 $[t_x, \theta_{roll}, \theta_{pitch}]$ 在第一步中。在第二步中，其余的转换 $[t_y, t_z, \theta_{yaw}, \theta_{yaw}]$ 是通过匹配从分割点云中提取的边缘特征获得的。我们还集成了执行环路闭合以校正运动估计漂移的能力。本文的其余部分组织如下。第二节介绍用于实验的硬件。第三节详细描述了所提出的方法。第四节介绍了在各种户外环境中进行的一组实验。

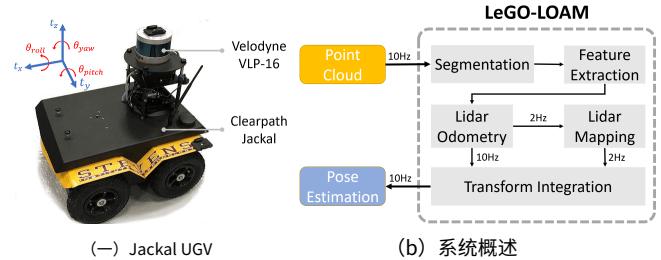


图 1：LeGO-LOAM 的硬件和系统概述。

二、S 系统硬件

本文提出的框架使用 Velodyne VLP-16 和 HDL-64E 3D 激光雷达收集的数据集进行了验证。VLP-16 的测量范围可达 100 米，精度为 ± 3 厘米。垂直视野 (FOV) 为 30° ($\pm 15^\circ$) 和 360 度的水平视野。 16 通道传感器提供 2° 水平角度分辨率从 0.1° 至 0.4° 根据旋转速率。本文中，我们选择 10Hz 的扫描速率，可提供 0.2° 。 $HDL-64E$ (本文通过 KITTI 数据集进行探索) 的水平视场也为 360° 但多出 48 个通道。 $HDL-64E$ 的垂直视场为 26.9° 。

本文使用的 UGV 是 Clearpath Jackal。它由 270 瓦时锂电池供电，最大速度为 2.0 米/秒，最大有效载荷为 20 公斤。Jackal 还配备了低成本惯性测量单元 (IMU)，即 CH Robotics UM6 方向传感器。

所提出的框架在两台计算机上进行了验证：一台 Nvidia Jetson TX2 和一台配备 2.5GHz i7-4710MQ CPU 的笔记本电脑。Jetson TX2 是一款配备 ARM Cortex-A57 CPU 的嵌入式计算设备。笔记本电脑 CPU 的选择与 [19] 和 [20] 中使用的计算硬件相匹配。本文中显示的实验仅使用这些系统的 CPU。

三、L 轻量大号雷达哦多美特里和米亚太

A. 系统概述

图 1 显示了所提框架的概述。该系统接收来自 3D 激光雷达的输入并输出 6 DOF 姿态估计。整个系统分为五个模块。第一个，分割，获取单次扫描的点云并将其投影到范围图像上进行分割。然后将分割的点云发送到特征提取模块。然后，激光雷达测距使用从前一个模块中提取的特征来查找与连续扫描相关的变换。这些特征在激光雷达测绘，将它们注册到全局点云地图。最后，转型整合模块融合了来自激光雷达测距和激光雷达测绘并输出最终的姿态估计。相对于 [19] 和 [20] 中原始的广义 LOAM 框架，所提出的系统旨在提高地面车辆的效率和准确性。下面介绍这些模块的详细信息。

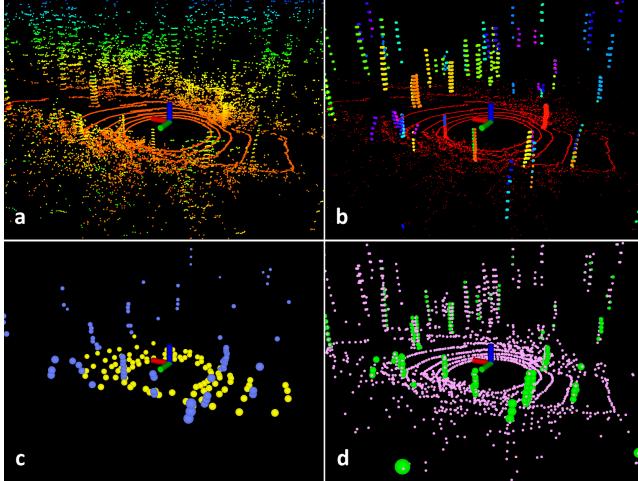


图 2：噪声环境中扫描的特征提取过程。原始点云如图 (a) 所示。在 (b) 中，红色点标记为地面点。其余点是分割后剩余的点。在 (c) 中，蓝色和黄色点表示边缘和平面特征 F_e 和 F_p 在 (d) 中，绿色和粉色点代表边缘和平面特征 F_e 和 F_p 分别。

B. 分割

让 $\text{页}_t = \{\text{页}_1, \text{页}_2, \dots, \text{页}_n\}$ 是时间获取的点云 吨 ，在哪里 页 我们是 $\text{磷}_{\text{吨}}$ 。磷 吨 首先投影到距离图像上。投影距离图像的分辨率为 1800×16 ，因为 VLP-16 的水平和垂直角度分辨率为 0.2° 和 2° 分别。每个有效点 页 在磷 吨 现在由范围图像中的唯一像素表示。范围值 r 我与 ... 相关 页 我

表示与相应点的欧几里得距离 页 我到传感器。由于在许多环境中，倾斜的地形很常见，因此我们不假设地面是平坦的。在分割之前，对距离图像进行逐列评估（可视为地面平面估计 [22]），以提取地面点。在此过程之后，可能代表地面的点被标记为地面点，不用于分割。

然后，将基于图像的分割方法 [23] 应用于范围图像，将点分组成多个聚类。来自同一聚类的点被分配一个唯一标签。请注意，地面点是一种特殊类型的聚类。对点云进行分割可以提高处理效率和特征提取精度。假设机器人在嘈杂的环境中操作，小物体（例如树叶）可能会形成破碎且不可靠的特征，因为同一片叶子不太可能在两次连续的扫描中看到。为了使用分割点云进行快速可靠的特征提取，我们省略了点少于 30 个的聚类。图 2 显示了分割前后点云的可视化效果。原始点云包含许多点，这些点是从周围的植被中获得的，可能会产生不可靠的特征。

经过此过程，只保留可能代表大物体（例如树干）和地面点的点（图 2 (b)），以供进一步处理。同时，只有这些点才会保存在深度图像中。我们还获得

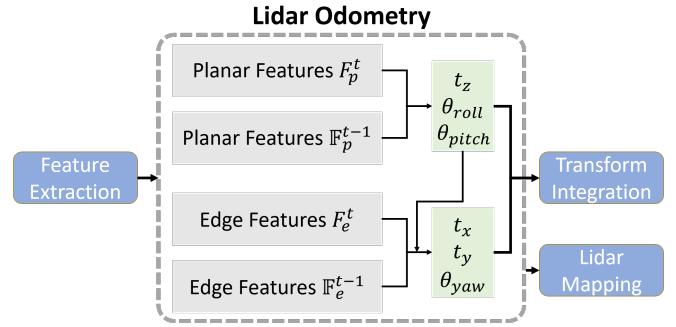


图 3：两步优化激光雷达测距模块。[t_z , θ_{roll} , θ_{pitch}]首先通过匹配从地面点提取的平面特征获得。[t_x , t_y , θ_{yaw}]然后使用从分割点提取的边缘特征进行估计，同时应用 [t_z , θ_{roll} , θ_{pitch}]作为约束。

每个点有三个属性：（1）其作为地面点或分割点的标签，（2）其在范围图像中的列和行索引，以及（3）其范围值。这些属性将在以下模块中使用。

C. 特征提取

特征提取过程与 [20] 中的方法类似。然而，我们不是从原始点云中提取特征，而是从地面点和分割点中提取特征。设年代是连续点的集合 页 我来自范围图像的同一行。年代在两边 页 我在本文中，我们设定 / 面 / 到 10。使用分割过程中计算的范围值，我们可以评估点的粗糙度 页 我在年代，

$$\text{丙} = \frac{1}{|S| \cdot \|r\|} \left\| \sum_{j \in S, i \in \text{我}} (r - \text{丙}) \right\|_2 \quad (1)$$

为了均匀地从各个方向提取特征，我们将距离图像水平划分为几个相等的子图像。然后根据粗糙度值对子图像每行中的点进行排序 丙 。与 LOAM 类似，我们使用阈值 $\text{丙}_{\text{日}}$ 区分不同类型的特征。我们称具有 丙 大于 $\text{丙}_{\text{日}}$ 边缘特点，以及要点 丙 小于 $\text{丙}_{\text{日}}$ 平面的功能。然后 $n_{\text{边}}$ 边缘特征点的最大 丙 ，不属于地面，是从子图像的每一行中选择出来的。 $n_{\text{平}}$ 平面特征点最小 丙 ，可以标记为地面点或分段点，以相同的方式选择。让 F_e 和 F_p 是所有子图像的所有边缘和平面特征的集合。这些特征在图 2(d) 中可视化。然后我们提取 $n_{\text{边}}$ 边缘特征最大 丙 ，不属于地面，从子图像的每一行中提取。同样，我们提取 $n_{\text{平}}$

埃

具有最小平面特征 丙 ，必须是地面点，来自子图像的每一行。让 F_e 和 F_p 是此过程中所有边缘和平面特征的集合。这里，我们有 $F_e \subset F_e$ 和 $F_p \subset F_p$ 。特点 F_e 和 F_p 如图 2(c) 所示。本文将 360° 将距离图像分割成 6 个子图像。每个子图像的分辨率为 300×16 。 n_{F_e} , n_{F_p} , n_{F_e} 和 n_{F_p} 分别选定为 2、4、40 和 80。

D. 激光雷达里程计

这激光雷达测距模块估计两次连续扫描之间的传感器运动。通过执行点到边和点到平面的扫描匹配来找到两次扫描之间的变换。换句话说，我们需要找到点的对应特征 F_{t-1}

F_{t-1} 和 F_t 从功能集 F_{t-1} 和 F_t 上次扫描的结果。为了简洁起见，找到这些对应关系的详细过程可以在[20]中找到。

然而，我们注意到可以进行一些改变来提高特征匹配的准确性和效率：

1) 标签匹配：由于每个特征 F_{t-1} 和 F_t 在分割后用其标签进行编码，我们只找到具有相同标签的对应关系 F_{t-1} 和 F_t 。对于平面特征 F_{t-1} 和 F_t ，只有标记的点作为地面点 F_{t-1} 用于寻找平面块作为对应关系。对于边缘特征 F_{t-1} 和 F_t 对应的边缘线 F_{t-1} 从分割的簇中找出对应关系。以这种方式找到对应关系有助于提高匹配准确率。换句话说，在两次扫描之间更有可能找到同一对象的匹配对应关系。这个过程也缩小了对应关系的潜在候选范围。

2) 两步LM优化：在[20]中，将当前扫描的边缘和平面特征点之间的距离与前一次扫描的对应关系的一系列非线性表达式编译成一个综合距离向量。采用 Levenberg-Marquardt (LM) 方法来寻找两次连续扫描之间的最小距离变换。

我们在这里介绍一种两步 LM 优化方法。最优变换由分两步找到：(1) $[t_1, \theta_{\text{卷}}, \theta_{\text{沥青}}]$ 通过匹配平面特征来估计

结构 F_{t-1} 以及他们的通信 F_{t-1} ，(2) 其余的 $[t_1, t_2, \theta_{\text{卷}}, \theta_{\text{偏航}}]$ 然后使用边缘进行估计特点 F_{t-1} 以及他们的通信 F_{t-1} 尽管使用 $[t_1, \theta_{\text{卷}}, \theta_{\text{沥青}}]$ 作为约束。需要注意的是，尽管 $[t_1, t_2, \theta_{\text{卷}}, \theta_{\text{偏航}}]$ 也可以从第一步优化中获得，但它们的准确性较低，不用于第二步。最后，通过融合 $[t_1, \theta_{\text{卷}}, \theta_{\text{沥青}}]$ 和 $[t_2, \theta_{\text{卷}}, \theta_{\text{偏航}}]$ 。通过使用提出的两步优化方法，我们观察到可以达到类似的精度，同时计算时间减少约35% (表III)。

E. 激光雷达测绘

这激光雷达测绘模块匹配功能 $\{F_{t-1}, F_t\}$ 到周围的点云图 \bar{F}_{t-1} 进一步细化姿态变换，但运行频率较低。然后再次使用 LM 方法来获得最终的变换。我们请读者参考[20]中的描述来了解详细的匹配和优化过程。LeGO-LOAM 的主要区别在于最终点云图的存储方式。它不是保存单个点

云图中，我们保存每个单独的特征集 $\{F_{t-1}, F_t\}$ 。让 $\bar{F}_{t-1} = \{F_1, F_2, \dots, F_{t-1}\}$ 成为拯救者

所有先前的功能集。每个功能集 \bar{F}_{t-1} 也与扫描时传感器的姿态有关。

然后 \bar{F}_{t-1} 可以从 \bar{F}_{t-1} 两种方式。

在第一种方法中， \bar{F}_{t-1} 是通过选择传感器视野范围内的特征集来获得的。为简单起见，我们可以选择传感器姿态在传感器当前位置 100 米以内的特征集。然后将所选特征集转换并融合到单个周围地图中 \bar{F}_{t-1} 这种地图选择技术与[20]中使用到的方法类似。

我们还可以将姿态图 SLAM 集成到 LeGO-LOAM 中。每个特征集的传感器姿态可以进行修改，元素作为位姿图中的节点。特征集 $\{F_{t-1}, F_t\}$ 能被视为该节点的传感器测量值。由于激光雷达测绘模块的姿态估计漂移非常低，我们可以认为没有漂移

它是短时间内。这样， \bar{F}_{t-1} 可以形成

通过选择最近的一组特征集，即 $\bar{F}_{t-1} = \{F_{t-1}, F_t\}$ ，在哪里 \bar{F}_{t-1} 定义大小的 \bar{F}_{t-1} 然后，新节点与所选节点之间的空间约束 \bar{F}_{t-1} 可以使用 LM 优化后获得的变换来添加。我们可以通过执行回环检测来进一步消除此模块的漂移。在这种情况下，如果使用 ICP 在当前特征集和先前特征集之间找到匹配，则会添加新的约束。然后通过将位姿图发送到优化系统（如[24]）来更新传感器的估计位姿。请注意，只有第 IV 节 (D) 中的实验使用此技术来创建其周围地图。

IV.E 实验

现在，我们描述了一系列实验，以定性和定量分析两种竞争方法 LOAM 和 LeGO-LOAM，它们在两种硬件配置上进行，一台是带有 Cortex-A57 的 Jetson TX2，另一台是带有 i7-4710MQ 的笔记本电脑。这两种算法都是用 C++ 实现的，并使用 Ubuntu Linux 中的机器人操作系统 (ROS) [25] 执行。

A. 小型 UGV 测试

我们在植被覆盖的室外环境中手动驾驶机器人。我们首先展示此环境中特征提取的定性比较。图 4 显示了使用两种方法从同一扫描中提取的边缘和平面特征。这些特征

对应于 $\{F_{t-1}, F_t\}$ 发送到激光雷达测绘模块中的第三部分。如图 4 (d) 所示，在点云分割后，LeGO-LOAM 的特征数量大大减少。从树叶返回的大多数点都被丢弃，因为它们在多次扫描中不是稳定的特征。另一方面，由于从草地返回的点也非常嘈杂，因此在评估后会得出很大的粗糙度值。因此，不可避免地使用

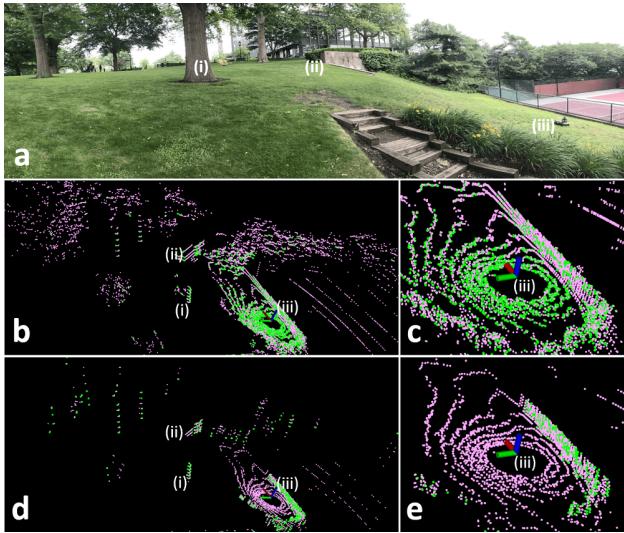


图4：在植被覆盖的室外环境中，从两种不同的激光雷达测距和测绘框架获得的边缘和平面特征。边缘和平面特征分别用绿色和粉色表示。从 LOAM 获得的特征如图(b) 和(c) 所示。从 LeGO-LOAM 获得的特征如图(d) 和(e) 所示。标签(i) 表示一棵树，(ii) 表示一堵石墙，(iii) 表示机器人。

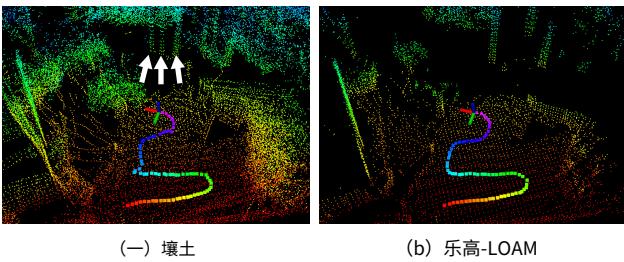


图5：LOAM 和 LeGO-LOAM 绘制的图4 (a) 中显示的地形地图。(a) 中用白色箭头标记的树木代表同一棵树。

原始 LOAM。如图 4(c) 所示，从地面提取的边缘特征通常不可靠。

虽然我们可以改变粗糙度阈值 ρ_B 在 LOAM 中提取边缘和平面特征以减少特征数量并过滤掉草和树叶中的不稳定特征时，我们在应用这些更改后遇到了更糟糕的结果。例如，我们可以增加 ρ_B 从环境中提取更稳定的边缘特征，但如果机器人进入相对干净的环境，这种变化可能会导致有用的边缘特征数量不足。同样，减少 ρ_B 当机器人从干净的环境移动到嘈杂的环境时，也会导致缺乏有用的平面特征。在所有实验中，我们使用相同的 ρ_B 适用于 LOAM 和 LeGO-LOAM。

现在我们比较一下映射在测试环境中，两种方法的结果相同。为了模拟具有挑战性的潜在 UGV 操作场景，我们执行了一系列激进的偏航操作。请注意，在本文的所有实验中，这两种方法都输入了相同的初始平移和旋转猜测，这些猜测是从 IMU 获得的。运行 60 秒后得到的点云图是

表一：大规模户外数据集

| 实验 | 扫描 数字 | 海拔 变化 (米) | 弹道 长度 (公里) |
|----|----------|--------------|---------------|
| 1 | 8077 | 11 | 1.09 |
| 2 | 8946 | 11 | 1.24 |
| 3 | 20834 | 19 | 2.71 |

如图 5 所示。由于不稳定特征导致的错误特征关联，LOAM 的地图在运行过程中出现两次发散。图 5 (a) 中用白色箭头突出显示的三棵树干代表现实中的同一棵树。两种里程计方法的完整地图绘制过程的可视化可以在视频附件中找到²。

B. 大型 UGV 测试

接下来，我们将在三个大规模数据集上对 LOAM 和 LeGO-LOAM 进行定量比较，这些数据集将被称为实验 1、2 和 3。前两个实验是在史蒂文斯理工学院的校园里收集的，那里有许多建筑物、树木、道路和人行道。这些实验及其环境如图 6 (a) 所示。实验 3 横跨一条森林徒步小径，其中有树木、柏油路和被草和土壤覆盖的小径。进行实验 3 的环境如图 8 所示。每个实验的详细信息列于表 I 中。为了进行公平的比较，每个实验显示的所有性能和准确性结果都是在每个数据集的 10 次实时回放试验中取平均值。

1) 实验1：第一个实验旨在证明 LOAM 和 LeGO-LOAM 均可在城市环境中实现低漂移姿态估计，且运动平稳。我们避免激进的偏航动作，并避免驾驶机器人穿过稀疏区域，因为在这些区域只能获取少量稳定特征。在整个数据记录过程中，机器人都在平坦的道路上运行。机器人的初始位置（如图 6(b) 所示）位于斜坡上。机器人经过 807 秒的行驶后返回同一位置，平均速度为 1.35 米/秒。

为了评估两种方法的姿态估计精度，我们比较了最终姿态和初始姿态之间的平移和旋转差异。这里，初始姿态定义为 [0, 0, 0, 0, 0, 0] 通过所有实验。如表 V 所示，LOAM 和 LeGO-LOAM 在两种不同的硬件配置上都实现了类似的低漂移姿势估计。在 Jetson 上运行时，LeGO-LOAM 的最终地图如图 6(b) 所示。

2) 实验2：虽然实验 2 与实验 1 是在相同的环境中进行的，但其轨迹略有不同，行驶在如图 7 (a) 所示的人行道上。这条人行道代表了 LOAM 经常会失败的环境。人行道的一端是一堵墙和几根柱子——从这些结构中提取的边缘和平面特征是稳定的。人行道的另一端是一片空旷的区域，上面布满了嘈杂的物体，即草和树，这将导致不可靠的特征提取。因此，LOAM 的姿态估计会发散

²https://youtu.be/O3tz_ftHV48

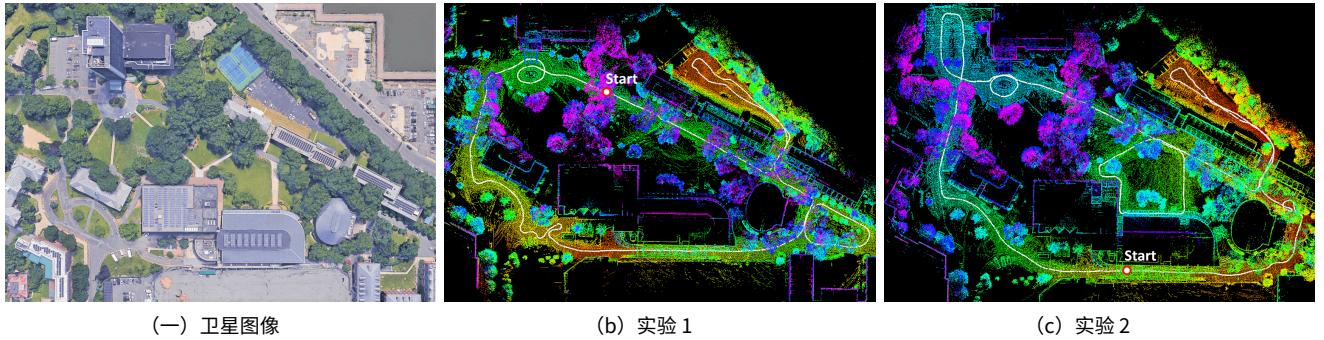


图6：实验1和2中的LeGO-LOAM地图。(c)中的颜色变化表示真实的海拔变化。由于实验1中机器人的初始位置在斜坡上，因此(b)中的颜色变化并不代表真实的海拔变化。

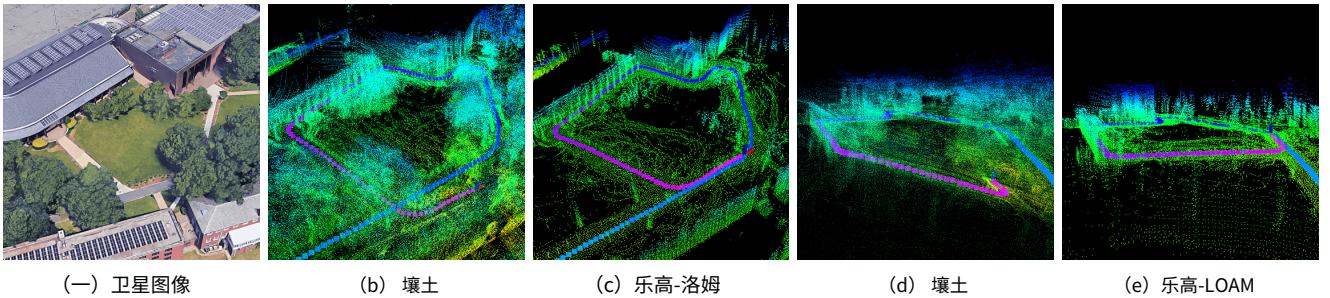


图7：实验2中LOAM在穿过史蒂文斯校园的人行道上失败的场景（上图(a)中最左边的人行道）。人行道的一端由附近建筑物的特征支撑。人行道的另一端主要被嘈杂的物体包围，即草地和树木。如果没有点云分割，将从这些物体中提取不可靠的边缘和平面特征。图像(b)和(d)显示LOAM在经过人行道后失败。



图8：实验3 LeGO-LOAM映射结果。

驶过这条人行道后（图7 (b) 和 (d)）。LeGO-LOAM不存在以下问题：1) 无法从草覆盖的地面提取边缘特征，2) 分割后树叶的噪声传感器读数被滤除。两种方法的精度比如表V所示。在本实验中，LeGO-LOAM的精度比LOAM高一个数量级。

3) 实验3：实验3的数据集是从森林徒步小径记录的，UGV的平均行驶速度为1.3米/秒。行驶35分钟后，机器人返回初始位置。此环境中的海拔变化约为19米。UGV在三种路面上行驶：泥土覆盖的小径、沥青和地面

被草覆盖。图8底部分别显示了此类表面的代表性图像。道路的至少一侧始终存在树木或灌木丛。

我们首先在此环境中测试LOAM的准确性。生成的地图在使用的两台计算机上的不同位置有所不同。相对于UGV的初始位置，最终的平移和旋转误差分别为69.40米和27.38°。在Jetson上，分别为62.11米和8.50°。在笔记本电脑上。图9 (a) 和 (b) 显示了在两种硬件配置上进行10次试验所得的轨迹。

当LeGO-LOAM应用于该数据集时，最终的相对平移和旋转误差分别为13.93米和7.73°。在Jetson上，分别为14.87米和7.96°。在笔记本电脑上。图8显示了Jetson上LeGO-LOAM的最终点云地图，该地图叠加在卫星图像上。图8中心放大的局部地图显示LeGO-LOAM的点云地图与空旷地带可见的三棵树非常匹配。两台计算机上从LeGO-LOAM获得的所有路径都具有高度一致性。图9 (c) 和 (d) 显示在每台计算机上运行了十次试验。

C. 基准测试结果

1) 特征数量比较：我们在表II中展示了两种方法的特征提取比较。每个数据集的每次扫描的特征内容在10次试验中取平均值。点云分割后，LeGO-LOAM需要处理的特征数量至少减少了29%、40%、68%和72%。 $F_{\text{埃}}$ ， $F_{\text{页}}$ ， $F_{\text{埃}}$ 和 $F_{\text{页}}$ 分别。

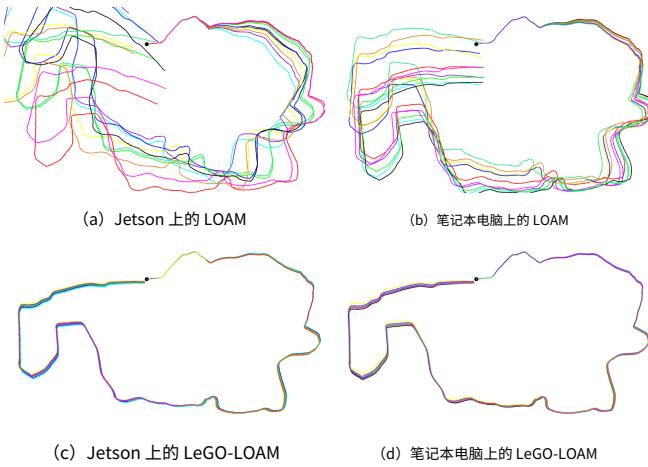


图 9: LOAM 和 LeGO-LOAM 在 10 次试验、2 台计算机中使用实验 3 的数据集生成的路径。

表二：特征提取后的扫描平均特征内容

| 设想 | 边缘 特征 $F_{\text{边缘}}$ | | 平面 特征 $F_{\text{平面}}$ | | 边缘 特征 $F_{\text{边缘}}$ | | 平面 特征 $F_{\text{平面}}$ | |
|----|--------------------------|----------|--------------------------|----------|--------------------------|----------|--------------------------|----------|
| | 壤土 | 乐高 壤土 | 壤土 | 乐高 壤土 | 壤土 | 乐高 壤土 | 壤土 | 乐高 壤土 |
| 1 | 157 | 102 | 323 | 152 | 878 | 253 | 4849 | 1319 |
| 2 | 145 | 102 | 331 | 154 | 798 | 254 | 4677 | 1227 |
| 3 | 174 | 101 | 172 | 103 | 819 | 163 | 6056 | 1146 |

2) 迭代次数比较：应用所提出的两步 LM 优化方法的结果如表 III 所示。我们首先将原始 LM 优化应用于 LeGO-LOAM，这意味着我们最小化从边缘和平面特征获得的距离函数。然后我们将两步 LM 优化应用于 LeGO-LOAM：1) 平面特征 $F_{\text{平面}}$ 用于获得 $[\Delta\theta_{\text{是}}, \theta_{\text{卷}}, \theta_{\text{沥青}}]$ ；2) 边缘特征 $F_{\text{边缘}}$ 用于获得 $[\Delta\theta_{+}, \Delta\theta_{\text{是}}, \theta_{\text{偏航}}]$ 。为了进行比较，记录了 LM 方法在处理一次扫描后终止时的平均迭代次数。当使用两步优化时，实验 1 和实验 2 中的第一步优化在 2 次迭代中完成。虽然第二步优化的迭代次数与原始 LM 方法的数量相似，但处理的特征较少。因此，激光雷达测距使用两步 LM 优化后，运行时间减少了 34% 至 48%。两步优化的运行时间如表 IV 所示。

3) 运行时比较：表 IV 显示了 LOAM 和 LeGO-LOAM 在两台计算机上每个模块的运行时间。使用所提出的框架，特征提取和激光雷达测距在 LeGO-LOAM 中，模块数量减少了一个数量级。请注意，LOAM 中这两个模块的运行时间在 Jetson 上超过 100 毫秒。因此，许多扫描被跳过，因为 LOAM 在嵌入式系统上无法实现实时性能。激光雷达测绘当使用 LeGO-LOAM 时也减少了至少 60%。

4) 位姿误差比较：通过将初始姿势设置为 $[0, 0, 0, 0, 0, 0]$ 在所有实验中，我们通过将最终姿势与

表三：LeGO-LOAM 迭代次数比较

| 设想 | 编号 | 时间 | 两步选择。 | |
|----|----|------|------------|-------------|
| | | | 步骤 1 编号 | 第 2 步 编号 |
| 长 | 1 | 16.6 | 34.5 | 1.9 17.5 |
| | 2 | 15.7 | 32.9 | 1.7 16.7 |
| | 3 | 20.0 | 27.7 | 4.7 18.9 |
| i7 | 1 | 17.3 | 13.1 | 1.8 18.2 |
| | 2 | 16.5 | 12.3 | 1.6 17.5 |
| | 3 | 20.5 | 10.4 | 4.7 19.8 |

表 IV：处理一次扫描的模块运行时间 (毫秒)

| 设想 | 分割 壤土 | 萃取 | | 里程计 | | 映射 | |
|----|----------|----------|------------|----------|-------|------------|-------|
| | | 乐高 壤土 | 壤土 | 乐高 壤土 | 壤土 | 乐高 壤土 | 壤土 |
| 长 | 1 | 不适用 | 29.3 105.1 | 9.1 | 133.4 | 19.3 702.3 | 266.7 |
| | 2 | 不适用 | 29.9 106.7 | 9.9 | 124.5 | 18.6 793.6 | 278.2 |
| | 3 | 不适用 | 36.8 104.6 | 6.1 | 122.1 | 18.1 850.9 | 253.3 |
| i7 | 1 | 不适用 | 16.7 50.4 | 4.0 | 69.8 | 6.8 289.4 | 108.2 |
| | 2 | 不适用 | 17.0 49.3 | 4.4 | 66.5 | 6.5 330.5 | 116.7 |
| | 3 | 不适用 | 20.0 48.5 | 2.3 | 63.0 | 6.1 344.9 | 101.7 |

初始姿态。表 V 列出了两种方法在两台计算机上的旋转误差（以度为单位）和平移误差（以米为单位）。通过使用所提出的框架，LeGO-LOAM 可以实现相当或更好的位置估计

用更少的计算时间实现更高的准确度。

D. 使用 KITTI 数据集进行回环测试

我们的最终实验将 LeGO-LOAM 应用于 KITTI 数据集 [21]。由于 [20] 中对 KITTI 数据集进行的 LOAM 测试以实时速度的 10% 运行，我们仅探索 LeGO-LOAM 及其在嵌入式系统中的实时应用潜力，其中行程长度足够长，需要完整的 SLAM 解决方案。图 10 显示了使用序列 00 的 Jetson 上的 LeGO-LOAM 的结果。为了在 Jetson 上实现实时性能，我们将 HDL-64E 的扫描下采样为与第 III 部分中用于 VLP-16 的相同范围图像。换句话说，在处理之前省略了每次扫描的 75% 的点。这里使用 ICP 在位姿图中的节点之间添加约束。然后使用 iSAM2 [24] 优化该图。最后，我们使用优化后的图来校正传感器姿势和地图。更多回环测试可以在视频附件中找到。

V、C 结论和德讨论

我们提出了一种轻量级、地面优化的激光雷达测距和测绘方法 LeGO-LOAM，用于在复杂环境中实时估计 UGV 的姿态。LeGO-LOAM 是轻量级的，因为它可以在嵌入式系统上使用并实现实时性能。LeGO-LOAM 还进行了地面优化，利用地面分离、点云分割和改进的 LM 优化。在此过程中，可能代表不可靠特征的无值点会被过滤掉。两步 LM 优化分别计算姿态变换的不同组件。在室外环境中收集的一系列 UGV 数据集上对所提出的方法进行了评估。结果表明，与最先进的方法相比，LeGO-LOAM 可以实现相似或更好的精度

表V：返回起点时的相对位姿估计误差

| 设想 | 方法 | 卷 | 沥青 | 偏航 | 全部的 度量。(.) | 十 | 是 | 是 | 全部的 传输(米) |
|--------------|--------------|---------------|--------------|---------------|---------------|---------------|----------------|----------------|----------------|
| 1 长 17 | 壤土 乐高LOAM | 1.16 0.46 | 2.63 0.91 | 2.5 1.98 | 3.81 2.23 | 1.33 0.12 | 2.91 0.07 | 0.43 1.26 | 3.23 1.27 |
| | 壤土 乐高LOAM | 7.05 0.61 | 5.06 0.70 | 9.4 0.32 | 12.80 0.99 | 7.71 0.04 | 6.31 0.10 | 4.32 0.34 | 10.86 0.36 |
| | 壤土 乐高LOAM | 7.55 4.62 | 3.20 5.45 | 26.12 2.95 | 27.38 7.73 | 34.61 5.35 | 56.19 7.95 | 21.46 10.11 | 69.40 13.93 |
| 2 17 | 壤土 乐高LOAM | 0.28 0.22 | 1.98 0.39 | 1.74 0.03 | 2.65 0.21 | 0.39 0.17 | 0.03 2.06 | 0.02 0.03 | 0.44 0.22 |
| | 壤土 乐高LOAM | 21.49 0.64 | 4.86 1.08 | 4.34 0.04 | 22.46 0.18 | 1.39 0.12 | 2.59 0.12 | 11.63 0.04 | 11.99 0.04 |
| | 壤土 乐高LOAM | 6.27 4.57 | 3.08 3.68 | 7.96 | 8.50 6.69 | 16.84 7.79 | 58.81 10.76 | 10.74 62.11 | 14.87 0.14 |

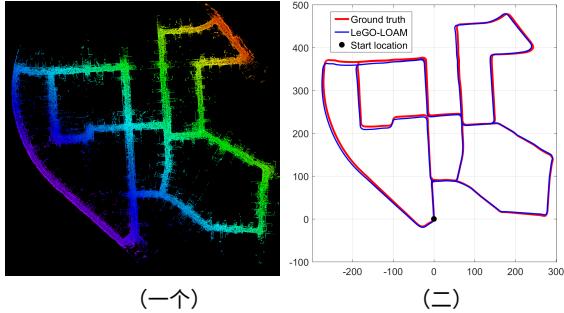


图 10：LeGO-LOAM，KITTI 数据集循环闭合测试，使用 Jetson。颜色变化表示海拔变化。

算法 LOAM。LeGO-LOAM 的计算时间也大大减少。未来的工作涉及探索其在其他类型车辆中的应用。

尽管 LeGO-LOAM 专门针对地面车辆的姿态估计进行了优化，但其应用可以扩展到其他车辆，例如无人机 (UAV)，只需进行微小的改动。将 LeGO-LOAM 应用于无人机时，我们不会假设地面存在于扫描中。扫描的点云将在没有地面提取的情况下进行分割。特征提取过程与选择 $F_{\text{块}}$ ， $F_{\text{块}}$ 和 $F_{\text{页}}$ 而不是提取平面特征 $F_{\text{页}}$ 从标记为地面点的点开始， $F_{\text{页}}$ 将从所有分割点中选择。然后使用原始 LM 方法来获得两次扫描之间的变换，而不是使用两步优化方法。虽然这些改变之后计算时间会增加，但 LeGO-LOAM 仍然很有效，因为分割后在嘈杂的室外环境中会省略大量点。估计的特征对应关系的准确性可能会提高，因为它们受益于分割。此外，使用 LeGO-LOAM 在线执行循环闭合的能力使其成为长时间导航任务的有用工具。

R参考文献

- [1] PJ Besl 和 ND McKay，“一种 3D 形状配准方法”，*IEEE 模式分析与机器智能学报*，第 14(2): 239-256, 1992.
- [2] S. Rusinkiewicz 和 M. Levoy，“ICP 算法的有效变体”，*第三届三维数字成像与建模国际会议论文集*，第 145-152 页，2001 年。
- [3] Y. Chen 和 G. Medioni，“通过多范围图像配准实现对象建模”*图像与视觉计算*，第 10 卷(3): 145-155, 1992.
- [4] A. Segal、D. Haehnel 和 S. Thrun，“广义 ICP”*机器人学论文集：科学与系统*，2009 年。
- [5] RA Newcombe、S. Izadi、O. Hilliges、D. Molyneaux、D. Kim、AJ Davison、P. Kohi、J. Shotton、S. Hodges 和 A. Fitzgibbon，“KinectFusion：实时密集表面映射和跟踪”，*IEEE 混合现实和增强现实国际研讨会论文集*，第 127-136 页，2011 年。
- [6] A. Nuchter，“机器人 3D 测绘的扫描匹配并行化”，*第三届欧洲移动机器人会议论文集*，2007 年。
- [7] D. Qiu、S. May 和 A. Nuchter，“GPU 加速的 3D 配准最近邻搜索”，*国际计算机视觉系统会议论文集*，第 194-203 页，2009 年。
- [8] D. Neumann、F. Lugauer、S. Bauer、J. Wasza 和 J. Hornegger，“使用随机球覆盖数据结构在 GPU 上进行实时 RGB-D 映射和 3D 建模”，*IEEE 国际计算机视觉会议研讨会*，第 1161-1167 页，2011 年。
- [9] RB Rusu、ZC Marton、N. Blodow 和 M. Beetz，“学习用于获取对象模型图的信息点类”，*IEEE 控制、自动化、机器人和视觉国际会议论文集*，第 643-650 页，2008 年。
- [10] RB Rusu、G. Bradski、R. Thibaux 和 J. Hsu，“利用视点特征直方图实现快速 3D 识别和姿势”，*IEEE/RSJ 智能机器人与系统国际会议论文集*，第 2155-2162 页，2010 年。
- [11] Y. Li 和 EB Olson，“通用激光雷达特征提取的结构张量”，*IEEE 机器人与自动化国际会议论文集*，第 1869-1874 页，2011 年。
- [12] J. Serafin、E. Olson 和 G. Grisetti，“从稀疏点云中进行快速而稳健的 3D 特征提取”，*IEEE/RSJ 智能机器人与系统国际会议论文集*，第 4105-4112 页，2016 年。
- [13] M. Bosse 和 R. Zlot，“2D 激光雷达地图中位置识别的关键点设计和评估”，*机器人和自主系统*，第 57 卷(12): 1211-1224, 2009。
- [14] R. Zlot 和 M. Bosse，“地下矿井的高效大规模 3D 移动测绘和表面重建”，*第八届现场和服务机器人国际会议论文集*，2012 年。
- [15] B. Steder、G. Grisetti 和 W. Burgard，“基于点特征的 3D 范围数据稳健位置识别”，*IEEE 机器人与自动化国际会议论文集*，第 1400-1405 页，2010 年。
- [16] WS Grant、RC Voorhies 和 L. Itti，“在 LiDAR 点云中寻找平面以实现时配准”，*IEEE/RSJ 智能机器人与系统国际会议论文集*，第 4347-4354 页，2013 年。
- [17] M. Velas、M. Spanel 和 A. Herout，“利用 Velodyne 点云快速估算里程的领线段”，*IEEE 机器人与自动化国际会议论文集*，第 4486-4495 页，2016 年。
- [18] R. Dube、D. Dugas、E. Stumm、J. Nieto、R. Siegwart 和 C. Cadena，“SegMatch：基于分段的 3D 点云位置识别”，*IEEE 机器人与自动化国际会议论文集*，第 5266-5272 页，2017 年。
- [19] J. Zhang 和 S. Singh，“LOAM：实时激光雷达里程计和测绘”，*机器人学论文集：科学与系统*，2014 年。
- [20] J. Zhang 和 S. Singh，“低漂移实时激光雷达里程计与测绘”，*自主机器人*，第 41(2): 401-416, 2017。
- [21] A. Geiger、P. Lenz 和 R. Urtasun，“我们准备好迎接自动驾驶了吗？KITTI 视觉基准套件”，*IEEE 国际计算机视觉与模式识别会议论文集*，第 3354-3361 页，2012 年。
- [22] M. Himmelsbach、FV Hundelshausen 和 H.J. Wuensche，“地面车辆 3D 点云快速分割”，*IEEE 智能汽车研讨会论文集*，第 560-565 页，2010 年。
- [23] I. Bogoslavskyi 和 C. Stachniss，“基于快速范围图像的稀疏 3D 激光扫描分割在线操作”，*IEEE/RSJ 智能机器人与系统国际会议论文集*，第 163-169 页，2016 年。
- [24] M. Kaess、H. Johannsson、R. Roberts、V. Ila、JJ Leonard 和 F. Dellaert，“iSAM2：使用贝叶斯树进行增量平滑和映射”，*国际机器人研究杂志* 31, 第 31 卷(2): 216-235, 2012。
- [25] M. Quigley、K. Conley、B. Gerkey、J. Faust、T. Foote、J. Leibs、R. Wheeler 和 A.Y. Ng，“ROS：开源机器人操作系统”*IEEE ICRA 开源软件研讨会*，2009 年。